

GAT-MARL: Điều phối mạng lưới đèn giao thông đô thị bằng Multi-Agent Reinforcement Learning và Graph Attention Network

Bài tập lớn — Môn Machine Learning, HK2 2025–2026

Đặng Quang Minh Ngô Trọng Hiệp Khổng Quang Huy

Viện Trí tuệ nhân tạo
Trường Đại học Công nghệ — ĐHQGHN

Nội dung trình bày

- 1 Giới thiệu bài toán
- 2 Kiến trúc GAT-MARL
- 3 Phương pháp training
- 4 Môi trường thực nghiệm
- 5 Kết quả thực nghiệm
- 6 Thảo luận & Kết luận

Vấn đề: Đèn giao thông truyền thống

Hạn chế của hệ thống cố định:

- Chu kỳ cứng nhắc, không phản ứng với lưu lượng thực tế
 - Mỗi ngã tư hoạt động độc lập, không phối hợp
 - Ùn tắc cục bộ lan sang toàn mạng
- [Ảnh: tắc đường thực tế / bản đồ khu vực Mỹ Đình]*

Mục tiêu: Hệ thống *adaptive* tối thiểu hóa thời gian chờ và tăng lưu lượng thông qua.

Decentralized Partially Observable MDP

Mỗi ngã tư i là một **agent** quyết định pha đèn dựa trên *quan sát cục bộ*.

Thành phần	Định nghĩa
Agents N	8 ngã tư (Mỹ Đình)
Observation	Queue, density, phase, Δt
Action	Keep / Switch pha
Reward	$-(\alpha \hat{w}_i + \beta \hat{p}_i) \times S$

Thách thức — Non-stationarity:


Khi agents đồng thời cập nhật policy, môi trường trở nên non-stationary từ góc nhìn mỗi agent $\Rightarrow$ Independent Q-Learning không hội tụ.

Kiến trúc mô hình GAT-MARL

3 module dùng chung trọng số:

- 1 **Local Encoder** (MLP)
 $obs_i \rightarrow h_i \in \mathbb{R}^{64}$
- 2 **GAT Layer** (4 heads)
 $h_i \rightarrow h'_i$ (aggregate neighbors)
- 3 **Q-head** (MLP)
 $h'_i \rightarrow Q(\text{keep}), Q(\text{switch})$

Parameter sharing: toàn bộ N agents dùng chung 1 bộ trọng số.




Graph Attention Network — Cơ chế giao tiếp

Hệ số attention giữa agent i và neighbor j :

$$\alpha_{ij} = \frac{\exp(\text{LReLU}(e_{ij}))}{\sum_{k \in \mathcal{N}_i} \exp(\text{LReLU}(e_{ik}))}$$

Ưu điểm:

- Không cần edge weights định trước
- Mức độ ảnh hưởng học được động theo traffic
- `concat=False` $\Rightarrow$ output giữ nguyên 64 chiều



Attention heatmap tại giờ cao điểm

Reward Function — Hybrid Waiting Time + Pressure

$$r_i = -(\alpha \cdot \hat{w}_i + \beta \cdot \hat{p}_i) \times S$$

Tại sao cần normalize?

- Không normalize: tỉ lệ thực tế **98:2**
(pressure bị triệt tiêu hoàn toàn)
- Có normalize: tỉ lệ thực tế **71:29**
($\approx \alpha:\beta = 70:30$ như thiết kế)

Shared reward (GAT-MARL)

$$r_i^{\text{train}} = 0.7 \cdot r_i + 0.3 \cdot \bar{r}$$

Giữ 70% tín hiệu per-agent để Q-values không collapse + 30% global mean để cooperative.


Parallel Training — Ape-X Style

Fixed-role epsilon workers:

$$\varepsilon_k = \varepsilon_{\max} - \frac{(\varepsilon_{\max} - \varepsilon_{\min}) \cdot k}{K - 1}$$

- $k = 0$: $\varepsilon = 1.0$ — explorer, phủ rộng state space
- $k = K - 1$: $\varepsilon = 0.1$ — near-greedy, on-policy data

Buffer *luôn* đa dạng từ đầu đến cuối training.



2-Phase Fine-tuning — Transfer Learning


Phase 1 — Freeze GAT (20 ep đầu)

GAT layer đóng băng, chỉ Q-head cập nhật.
GAT đã học *graph topology knowledge* có tính tổng quát cao.

Phase 2 — Unfreeze toàn bộ

Fine-tune toàn bộ với LR thấp (đã qua warmup).

IDQN: không có module tách biệt
⇒ phải train lại từ đầu khi đổi map.



Môi trường mô phỏng SUMO

Hai mạng lưới thực tế tại Hà Nội:

- **Mỹ Đình** — 8 ngã tư
Arterial: Hồ Tùng Mậu, Lê Đức Thọ, Phạm Hùng
Secondary: Hàm Nghi, Nguyễn Hoàng, ...
- **UET** — 15 ngã tư
Phức tạp hơn, dùng để kiểm chứng transfer learning

Cấu hình: 1800s/episode, $\Delta t = 5s$,
3 kịch bản lưu lượng: sáng / chiều / đêm.




Mỹ Đình (8 ngã tư)



UET (15 ngã tư)

Kết quả — Map Mỹ Đình (500 episodes)



Metric	Fixed	IDQN	GAT
Reward $\uparrow$	-364	-260	-340
Wait (s) $\downarrow$	5.18	3.99	4.46
Speed $\uparrow$	18.9	21.9	18.7

Lưu ý throughput

Fixed-time có throughput cao hơn vì SUMO inject xe đều đặn hơn — không phản ánh chất lượng điều phối thực sự.


Transfer Learning — Mỹ Đình → UET

Phương pháp	Conv.	Reward
GAT-MARL (finetune)	20 ep	-648 ± 320
IDQN (scratch)	25 ep	-689 ± 325
Fixed-time	—	-768 ± 301

*Conv.: số episodes đạt rolling-5 mean ≥ -569


GAT-MARL học nhanh hơn và reward cuối tốt hơn nhờ tái sử dụng graph topology knowledge từ Mỹ Đình.

Map UET — 15 ngã tư



Map UET — 15 ngã tư

Dashboard Real-time



FastAPI + WebSocket backend / React + Vite frontend. So sánh trực tiếp Fixed-time, IDQN, GAT-MARL trên cùng episode.

Tại sao GAT thua IDQN ở Mỹ Đình?

- 1 **Credit assignment** bất ổn:
Hybrid reward + obstacle $\Rightarrow$ episodes "thảm họa"
(min reward = -1525 vs -882 của IDQN)
- 2 **Graph quá nhỏ** ($N = 8$):
4 heads để học pattern trùng lặp
 $\Rightarrow$ overfit, không generalize

GAT phát huy khi graph đủ lớn (UET):

- Attention có ý nghĩa hơn trên 15 ngã tư
- Knowledge transfer hiệu quả qua 2-phase fine-tuning

Hướng phát triển:

- Prioritized experience replay
- Action space đa phase
- Mạng lưới >15 ngã tư

Đóng góp chính

- **Reward hybrid** với normalization đảm bảo $\alpha:\beta = 70:30$ thực sự
- **Parallel training** Ape-X style với fixed-role epsilon workers
- **2-phase fine-tuning**: GAT-MARL finetune **200 ep** đạt kết quả tốt hơn IDQN train từ đầu **500 ep** — ít tài nguyên hơn, hiệu quả hơn
- **Dashboard real-time** so sánh 3 phương pháp song song

Cảm ơn thầy/cô và các bạn đã lắng nghe!

{24022397, 24022325, 24022355}@vnu.edu.vn

<https://github.com/MinhCYB/Traffic-MARL>